

Inférence Bayésienne pour la prévision du comportement Thermo-Hydro-Mécanique à long terme d'ouvrages de confinement

Donatien Rossat - EDF R&D

16ème Colloque National en Calcul des Structures - CSMA 2024

13-17 Mai 2024, Presqu'île de Giens (Var, France)



Introduction

Inférence Bayésienne

Application aux enceintes de confinement

Conclusions et perspectives

Introduction


Inférence Bayésienne

Application aux enceintes de confinement

Conclusions et perspectives

Contexte industriel


- Le **confinement de la radioactivité** joue un rôle important dans la sûreté des réacteurs des centrales nucléaires de production d'électricité



Principe de fonctionnement d'un réacteur nucléaire ©EDF

Contexte industriel

- ▶ Le **confinement de la radioactivité** joue un rôle important dans la sûreté des réacteurs des centrales nucléaires de production d'électricité
- ▶ Les **enceintes de confinement** constituent de grands ouvrages en béton armé et précontraint, constituant la dernière barrière de confinement des réacteurs



Principe de fonctionnement d'un réacteur nucléaire ©EDF

Contexte industriel

- ▶ Le **confinement de la radioactivité** joue un rôle important dans la sûreté des réacteurs des centrales nucléaires de production d'électricité
- ▶ Les **enceintes de confinement** constituent de grands ouvrages en béton armé et précontraint, constituant la dernière barrière de confinement des réacteurs
- ▶ L'**étanchéité** des enceintes est contrôlée périodiquement via des essais de pressurisation, réalisés au cours de **Visites Décennales** (VD)





Schéma de la durée de fonctionnement typique d'une enceinte de confinement

Problématique - Modélisation et incertitudes

- L'étanchéité des enceintes peut évoluer au cours du temps sous l'effet de multiples phénomènes physiques liés au **vieillessement**



Chemins de fuite potentiels lors d'un essai décennal

Problématique - Modélisation et incertitudes



- ▶ L'étanchéité des enceintes peut évoluer au cours du temps sous l'effet de multiples phénomènes physiques liés au **vieillissement**
- ▶ Les récentes avancées en termes expérimentaux et numériques ont permis le développement de **modèles** visant à décrire les effets du vieillissement sur le comportement **THMF (Thermo-Hydro-Mécanique-Fuite)** à long terme des enceintes

Problématique - Modélisation et incertitudes



- ▶ L'étanchéité des enceintes peut évoluer au cours du temps sous l'effet de multiples phénomènes physiques liés au **vieillissement**
- ▶ Les récentes avancées en termes expérimentaux et numériques ont permis le développement de **modèles** visant à décrire les effets du vieillissement sur le comportement **THMF (Thermo-Hydro-Mécanique-Fuite)** à long terme des enceintes
- ▶ Néanmoins, malgré leur fidélité croissante, ces modèles demeurent des représentations idéalisées de la réalité !
 - simplifications physiques
 - schémas numériques : erreurs de discrétisation (e.g. différences finies, éléments finis)
 - incertitudes des paramètres
- ▶ Nécessité de prendre en compte les **incertitudes** entachant les prévisions des modèles

Motivations et objectifs



- ▶ Proposition d'une méthodologie permettant de modéliser les **incertitudes** dans les prévisions du comportement **multi-physique** à long terme d'enceintes (Rossat, 2022)
 - ▶ Établissement d'une **connexion** entre des modèles numériques et des données de mesures *in-situ*, permettant d'extraire de l'information au sujet de paramètres d'entrée incertains dans le cadre de **problèmes inverses**
 - ▶ **Actualisation** des prévisions et de leurs incertitudes, et quantification des risques associés à l'exploitation à long terme d'enceintes de confinement
- ⇒ Recours au cadre général de l'**inférence Bayésienne** : permet de quantifier les incertitudes de paramètres d'entrée à partir de données d'observation de la réponse d'un système (Kaipio et Somersalo, 2005; Tarantola, 2005)


Introduction

Inférence Bayésienne

Application aux enceintes de confinement

Conclusions et perspectives

Quantification d'Incertitudes - Cadre général



Définition du modèle

- Formalisation mathématique d'un **modèle** : application **déterministe**

$$\begin{aligned}\mathcal{M} : \mathcal{D}_X \subset \mathbb{R}^d &\rightarrow \mathcal{D}_Y \subset \mathbb{R}^n \\ x &\mapsto y = \mathcal{M}(x)\end{aligned}$$

- $x \in \mathcal{D}_X$: **paramètres d'entrée** (e.g. conductivité thermique, module d'Young)
- $y = \mathcal{M}(x) \in \mathcal{D}_Y$: **réponse** du modèle (e.g. température, déformation)
- Exemples de modèles : formule analytique, EDP discrétisée via un schéma numérique (e.g. éléments finis), chaîne de calcul multi-physique

Inférence Bayésienne



- ▶ Les **paramètres** et les **observables** sont représentés par deux variables aléatoires X et Y
- ▶ Définition de la **loi conditionnelle** de Y sachant $X = x$:

$$Y|X = x \sim \pi_{Y|X}(y|x)$$

⇒ **vraisemblance** $\mathcal{L}(x) = \pi_{Y|X}(y|x)$ pour $y \in \mathcal{D}_Y$ fixé

- ▶ Définition de la **densité a priori** $\pi_X(x)$ des paramètres X
- ▶ Détermination de la **densité a posteriori** via le théorème de Bayes :

$$\pi_{X|Y}(x|y) = \frac{\mathcal{L}(x)\pi_X(x)}{Z} \quad \text{où} \quad Z = \int_{\mathcal{D}_X} \mathcal{L}(x)\pi_X(x)dx$$

Problèmes inverses Bayésiens

- Cas particulier des **problèmes inverses Bayésiens** : vraisemblance $\mathcal{L}$ fonction du modèle $\mathcal{M}$
- Exemple d'un **modèle additif Gaussien** : (Kaipio et Somersalo, 2005; Tarantola, 2005)

$$Y = \mathcal{M}(x) + E$$

où $x \in \mathcal{D}_X$ est une réalisation de X , et $E \sim \mathcal{N}(\mathbf{0}, \Sigma)$ avec $\Sigma \in \mathbb{R}^{n \times n}$ définie positive




Schéma de principe d'un problème inverse Bayésien

Prise en compte d'un bruit inconnu et d'un biais de modèle

- ▶ La matrice de covariance Σ est rarement connue en général
 $\Rightarrow$ définition d'une **forme paramétrée** $\Sigma(\eta)$, où $\eta \in \mathcal{D}_N \subset \mathbb{R}^{d'}$ est une réalisation d'une variable aléatoire $N \sim \pi_N(\eta)$
- ▶ Prise en compte d'un **biais de modèle** via une fonction $\delta : \mathcal{D}_B \subset \mathbb{R}^{d''} \longrightarrow \mathcal{D}_Y$, paramétrée par une variable aléatoire $B \sim \pi_B(\beta)$
- ▶ Définition de la **densité jointe a priori** des paramètres $\Theta = (X, N, B)$ (supposés indépendants) :

$$\pi_{\Theta}(\theta) = \pi_X(x)\pi_N(\eta)\pi_B(\beta)$$

- ▶ Modèle additif Gaussien **avec bruit inconnu et biais de modèle** :

$$Y = \mathcal{M}(x) + E + \delta(\beta)$$

où $x \sim \pi_X(x)$, $E|N = \eta \sim \mathcal{N}(\mathbf{0}, \Sigma(\eta))$ et $\beta \sim \pi_B(\beta)$

Prise en compte d'un bruit inconnu et d'un biais de modèle

- ▶ La matrice de covariance Σ est rarement connue en général
 $\Rightarrow$ définition d'une **forme paramétrée** $\Sigma(\eta)$, où $\eta \in \mathcal{D}_N \subset \mathbb{R}^{d'}$ est une réalisation d'une variable aléatoire $N \sim \pi_N(\eta)$
- ▶ Prise en compte d'un **biais de modèle** via une fonction $\delta : \mathcal{D}_B \subset \mathbb{R}^{d''} \longrightarrow \mathcal{D}_Y$, paramétrée par une variable aléatoire $B \sim \pi_B(\beta)$
- ▶ Inférence des paramètres Θ via le **théorème de Bayes**, pour des données $y \in \mathcal{D}_Y$ fixées :


$$\pi_{\Theta|Y}(\theta|y) = \frac{\ell(\theta)\pi_{\Theta}(\theta)}{\mathcal{Z}}$$

$$\mathcal{Z} = \int_{\mathcal{D}_{\Theta}} \ell(\theta)\pi_{\Theta}(\theta)d\theta$$

avec $\ell(\theta) = \pi_{Y|\Theta}(y|\theta)$ et $\mathcal{D}_{\Theta} = \mathcal{D}_X \times \mathcal{D}_N \times \mathcal{D}_B$

Échantillonnage de la loi *a posteriori*

- ▶ La densité *a posteriori* est rarement connue analytiquement $\Rightarrow$ recours à des méthodes numériques
- ▶ Utilisation de méthodes de type MCMC (*Markov Chain Monte Carlo*) pour échantillonner la densité *a posteriori*
(Robert et Casella, 2004; Straub et Papaioannou, 2015)
- ▶ Algorithmes très coûteux en appels au modèle ($\mathcal{O}(10^6)$)
 $\Rightarrow$ utilisation de méta-modèles (*i.e.*, approximations rapides à évaluer)



Méta-modélisation par chaos polynomiaux

- Approximation par **chaos polynomiaux** dans le cas d'un modèle à valeurs *scalaires* $\mathcal{G} : \mathcal{D}_X \longrightarrow \mathbb{R}$:

$$\mathcal{G}(x) \approx \hat{\mathcal{G}}(x) = \sum_{\alpha \in \mathcal{A}} c_{\alpha} \psi_{\alpha}(x)$$

(Ghanem et Spanos, 1991)

$\mathcal{A} \subset \mathbb{N}^d$: multi-indices

c_{α} : coefficients (à calculer)

ψ_{α} : **polynômes orthogonaux** au sens de la densité (*a priori*) π_X de X

- Calcul des coefficients possible de manière **non intrusive**, à partir d'échantillons $\{x^{(k)}\}_{1 \leq k \leq N}$ et d'évaluations $\{\mathcal{G}(x^{(k)})\}_{1 \leq k \leq N}$ du modèle
(Lüthen et al., 2021)
- Utilisation d'une procédure de régression creuse basée sur l'algorithme **Least Angle Regression (LARS)**
(Blatman et Sudret, 2011)

Réduction de dimension par Analyses en Composantes Principales



- Dans le cas d'un modèle à valeurs *vectorielles* $\mathcal{M} : \mathcal{D}_{\mathbf{X}} \longrightarrow \mathcal{D}_{\mathbf{Y}} \subset \mathbb{R}^n$, le nombre n de composantes de sortie peut être important ($\mathcal{O}(10^3)$)
⇒ construction directe (*i.e.* un par composante) de chaos polynomiaux coûteuse

Réduction de dimension par Analyses en Composantes Principales



- ▶ Dans le cas d'un modèle à valeurs *vectorielles* $\mathcal{M} : \mathcal{D}_{\mathbf{X}} \longrightarrow \mathcal{D}_{\mathbf{Y}} \subset \mathbb{R}^n$, le nombre n de composantes de sortie peut être important ($\mathcal{O}(10^3)$)
 $\Rightarrow$ construction directe (*i.e.* un par composante) de chaos polynomiaux coûteuse
- ▶ Réduction de dimension par **Analyse en Composantes Principales (ACP)** (Blatman et Sudret, 2014)
 - Décomposition spectrale de la matrice de covariance $\Sigma_{\mathbf{Y}}$ de la réponse du modèle $\mathbf{Y} = \mathcal{M}(\mathbf{X})$:

$$\Sigma_{\mathbf{Y}} = \mathbf{W} \Lambda \mathbf{W}^{\top}$$

où $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ (et $\lambda_1 \geq \dots \lambda_n \geq 0$) valeurs propres et $\mathbf{W} \in \mathbb{R}^{n \times n}$ vecteurs propres de $\Sigma_{\mathbf{Y}}$

- Troncature du spectre via un critère d'énergie $\Rightarrow$ sélection des $r \geq 1$ premières valeurs propres $\lambda_1, \dots, \lambda_r$
- Projection de la réponse du modèle dans la base des r vecteurs propres $\mathbf{W}_r \in \mathbb{R}^{n \times r}$ correspondants :

$$\mathbf{Z} = \mathbf{W}_r^{\top} (\mathbf{Y} - \mathbb{E}[\mathbf{Y}])$$

- Construction d'un chaos polynomial de chaque composante Z_k de $\mathbf{Z}$, pour tout $k \in \{1, \dots, r\}$
- $\Rightarrow$ Réduction significative du coût de construction du méta-modèle ($r \ll n$ en pratique)

Introduction


Inférence Bayésienne

Application aux enceintes de confinement

Conclusions et perspectives

Cas de la maquette VeRCoRs


- 1^{er} objet d'étude : *maquette VeRCoRs (Vérification Réaliste du Confinement des Réacteurs)*, construite par EDF en 2014 (Charpin et al., 2021)



Vue aérienne et schéma de la maquette VeRCoRs - EDF Lab Les Renardières ©EDF


Cas de la maquette VeRCoRs

► Maquette à l'échelle 1 :3 d'une enceinte double paroi, largement instrumentée



(a) Vue en coupe de l'enceinte interne ;


(b) détail de la zone courante



Mesures de déformations en zone courante

Modélisation multi-physique du vieillissement

- Description des effets du vieillissement par un **modèle THML chaîné** (Rossat et al., 2022a,b)




- Modèles chaînés : résultent de simplifications de modèles **fortement couplés**, valables à l'échelle de larges structures en conditions d'exploitation standard
- Chaînage THML entièrement basé sur `code_aster` (Électricité de France, 2024)
- **Calculs thermo-hydrauliques** : température, séchage
 - **Calculs mécaniques** : contraintes, déformations différées (retrait et fluage)
 - **Calculs de fuites** : fuites poreuses et fuites locales (e.g. écoulements en milieu fissuré)

Modèle de partie courante d'enceinte

- Modèle aux éléments finis d'une **partie courante** de l'enceinte interne de VeRCoRs

(Rossat, 2022; Rossat et al., 2022c)



(a) géométrie; (b) maillage "thermique";

(c) maillage "mécanique"; (d) câbles de précontrainte;

- Chargement thermo-hydrigue : température et humidité relative ambiants
- Conditions aux limites axisymétriques, déplacement vertical nul sur la face inférieure, uniforme sur la face supérieure
- Précontrainte : forces nodales aux noeuds extrémités

Inférence Bayésienne des paramètres THM

- Inférence Bayésienne à partir de M séries de mesures de déformations différées $(\varepsilon_k)_{k \in \{1, \dots, M\}}$
(Rossat, 2022; Rossat et al., 2023)

- Proposition de deux formulations des écarts mesures (Y_{ε_k}) - modèle EF $(\mathcal{M}_{\varepsilon_k})$:

- (a) **variance inconnue** Σ^2 , modèle sans biais :

$$Y_{\varepsilon_k} | (X, \Sigma^2) = (x, \sigma^2) \sim \mathcal{N}(\mathcal{M}_{\varepsilon_k}(x), \sigma^2 \mathbf{I})$$

- (b) **variance inconnue** Σ^2 , modèle **avec biais** $B = (B_1, \dots, B_M)$:


$$Y_{\varepsilon_k} | (X, \Sigma^2, B_k) = (x, \sigma^2, \beta_k) \sim \mathcal{N}(\mathcal{M}_{\varepsilon_k}(x) + \beta_k \mathbf{1}, \sigma^2 \mathbf{I})$$

où $\mathbf{1} = (1, \dots, 1)$ (*biais constant dans le temps*)

- Lois *a priori* : paramètres THM $X \sim \pi_X(x)$, variance $\Sigma^2 \sim \mathcal{U}([0, \sigma_{\max}^2])$, biais $B_k \sim \text{Laplace}(0, \sigma_{\beta_k})$

Paramètres THM *a posteriori*

- Échantillonnage des lois *a posteriori* via l'algorithme **Subset Simulation** (SuS), accéléré par **chaos polynomiaux** (Rossat et al., 2023)



B Paramètre de séchage

$C_{w,0}$ Teneur en eau initiale

α_{ds} Paramètre de retrait de dessiccation

$\sigma_{\theta,0}$ Tension initiale des câbles tangentiels


$\sigma_{z,0}$ Tension initiale des câbles verticaux

κ Paramètre de fluage propre


Paramètres THM *a priori* (en gris) et *a posteriori* (en bleu)

Actualisation des prévisions des déformations

► Prévisions de l'évolution temporelle de déformations *a priori* vs. *a posteriori* :




Déformations tangentielles a priori




Déformations tangentielles a posteriori

Paramètres de variance et de biais de modèle

- Inférence de la variance du bruit d'observation et des biais, conjointement aux paramètres THM




Densités a priori et a posteriori de la variance Σ^2 - Cas sans biais (en bleu) et avec biais (en orange)




Paramètres de biais de modèle B a priori (en gris) et a posteriori (en bleu)

Déformations *a posteriori* - Effet du biais de modèle

- Effet de la prise en compte de biais de modèle sur les prédictions *a posteriori* :



Cas (a) : sans biais



Cas (b) : avec biais

Introduction

Inférence Bayésienne

Application aux enceintes de confinement

Conclusions et perspectives

Conclusions et perspectives



- ▶ Développement d'une méthodologie **probabiliste** de prévision du comportement multi-physique d'ouvrages de confinement sujets au vieillissement
- ▶ Établissement d'une **connexion** entre des modèles numériques et des données de mesures *in-situ* via l'**inférence Bayésienne**, permettant l'actualisation de prévisions à long terme
- ▶ Utilisation de méta-modèles "**prior-based**" pour accélérer des algorithmes d'inférence Bayésienne $\Rightarrow$ proposition de méthodologies adaptatives (Rossat et al., 2022a)
- ▶ Étude de l'impact du **choix de la loi a priori** sur les résultats d'inférence Bayésienne (Ruggeri et al., 2005; Stenger, 2020)

Merci pour votre attention !

- Blatman, G. et Sudret, B. 2011. Principal component analysis and Least Angle Regression in spectral stochastic finite element analysis. In *Applications of Statistics and Probability in Civil Engineering*, pages 669–676. CRC Press. doi : [10.1201/b11332-101](https://doi.org/10.1201/b11332-101).
- Blatman, G. et Sudret, B. 2014. Sparse polynomial chaos expansions of vector-valued response quantities. In *Safety, Reliability, Risk and Life-Cycle Performance of Structures and Infrastructures*, pages 3245–3252. CRC Press. doi : [10.1201/b16387-469](https://doi.org/10.1201/b16387-469).
- Charpin, L., Niepceron, J., Corbin, M., Masson, B., Mathieu, J.-P., Haelewyn, J., Hamon, F., Åhs, M., Aparicio, S., Asali, M., Capra, B., Azenha, M., Bouhjiti, D. E.-M., Calonius, K., Chu, M., Herrman, N., Huang, X., Jiménez, S., Mazars, J., Mosayan, M., Nahas, G., Stepan, J., Thenint, T., et Torrenti, J.-M. 2021. Ageing and air leakage assessment of a nuclear reactor containment mock-up : VERCORS 2nd benchmark. *Nuclear Engineering and Design*, 377 :111136. doi : [10.1016/j.nucengdes.2021.111136](https://doi.org/10.1016/j.nucengdes.2021.111136).
- Électricité de France 1989–2024. Finite element code_aster, Analysis of Structures and Thermomechanics for Studies and Research. Open source on www.code-aster.org.
- Ghanem, R. et Spanos, P. 1991. *Stochastic finite elements - A spectral approach*. Springer Verlag. doi : [10.1007/978-1-4612-3094-6](https://doi.org/10.1007/978-1-4612-3094-6).
- Kaipio, J. et Somersalo, E. 2005. *Statistical and Computational Inverse Problems*. Springer. doi : [10.1007/b138659](https://doi.org/10.1007/b138659).

- Lüthen, N., Marelli, S., et Sudret, B. 2021. Sparse Polynomial Chaos Expansions : Literature Survey and Benchmark. *SIAM/ASA Journal on Uncertainty Quantification*, 9(2) :593–649. doi : [10.1137/20M1315774](https://doi.org/10.1137/20M1315774).
- Robert, C. P. et Casella, G. 2004. *Monte Carlo Statistical Methods*. Springer Series in Statistics. Springer, New York, 2nd edition. doi : [10.1007/978-1-4757-4145-2](https://doi.org/10.1007/978-1-4757-4145-2).
- Rossat, D. 2022. *Quantification d'incertitudes inverse par inférence Bayésienne pour des modèles multi-physiques de grands ouvrages de confinement*. PhD thesis, Université Grenoble Alpes.
- Rossat, D., Baroth, J., Briffaut, M., et Dufour, F. 2022a. Bayesian inversion using adaptive Polynomial Chaos Kriging within Subset Simulation. *Journal of Computational Physics*, 455 :110986. doi : [10.1016/j.jcp.2022.110986](https://doi.org/10.1016/j.jcp.2022.110986).
- Rossat, D., Baroth, J., Briffaut, M., Dufour, F., Masson, B., Monteil, A., et Michel-Ponnelle, S. 2022b. Bayesian updating for nuclear containment buildings using both mechanical and hydraulic monitoring data. *Engineering Structures*, 262 :114294. doi : [10.1016/j.engstruct.2022.114294](https://doi.org/10.1016/j.engstruct.2022.114294).
- Rossat, D., Baroth, J., Briffaut, M., Dufour, F., Masson, B., Monteil, A., et Michel-Ponnelle, S. 2022c. Bayesian updating for predictions of delayed strains of large concrete structures : influence of prior distribution. *European Journal of Environmental and Civil Engineering*. doi : [10.1080/19648189.2022.2095441](https://doi.org/10.1080/19648189.2022.2095441).

- Rossat, D., Baroth, J., Briffaut, M., Dufour, F., Monteil, A., Masson, B., et Michel-Ponnelle, S. 2023. Bayesian inference with correction of model bias for Thermo-Hydro-Mechanical models of large concrete structures. *Engineering Structures*, 278 :115433. doi : [10.1016/j.engstruct.2022.115433](https://doi.org/10.1016/j.engstruct.2022.115433).
- Ruggeri, F., Ríos Insua, D., et Martín, J. 2005. Robust Bayesian Analysis. In Dey, D. et Rao, C., Eds., *Bayesian Thinking*, volume 25 of *Handbook of Statistics*, pages 623–667. Elsevier. doi : [10.1016/S0169-7161\(05\)25021-6](https://doi.org/10.1016/S0169-7161(05)25021-6).
- Stenger, J. 2020. *Optimal uncertainty quantification of a risk measurement from a computer code*. PhD thesis, Université Toulouse 3.
- Straub, D. et Papaioannou, I. 2015. Bayesian Updating with Structural Reliability Methods. *Journal of Engineering Mechanics*, 141(3) :04014134. doi : [10.1061/\(asce\)em.1943-7889.0000839](https://doi.org/10.1061/(asce)em.1943-7889.0000839).
- Tarantola, A. 2005. *Inverse Problem Theory and Methods for Model Parameter Estimation*. Society for Industrial and Applied Mathematics. doi : [10.1137/1.9780898717921](https://doi.org/10.1137/1.9780898717921).